Unidad 1 – Práctica

Modelos Generativos y LLMs

Nombre y apellido: _____Gaizka Martín Fernández_____

Fecha: _____19/03/2026_____

Parte 1. Selección de Técnicas Generativas

Ejercicio 1.1: Casos de uso

Caso de uso	Técnica	Justificación
App móvil que aplica filtros artísticos a fotos en tiempo real (<100ms)	GAN	Permite transformar imágenes con inferencia muy rápida, algo clave para tiempo real y filtros de estilo.
Plataforma de generación de arte digital de alta calidad con control por texto	Difusión	Ofrece muy buena calidad visual y un control fino del resultado mediante prompts de texto.
Detección de anomalías en imágenes médicas con espacio latente interpretable	VAE	Aprende un espacio latente continuo e interpretable, útil para comparar lo normal con lo anómalo.
Generador de datos sintéticos para reconocimiento facial preservando privacidad	GAN	Puede crear rostros sintéticos realistas para ampliar datasets sin usar directamente imágenes reales.
Asistente virtual que responde preguntas sobre documentación técnica	LLM	Está diseñado para comprender lenguaje natural y responder de forma contextual a partir de texto.
Herramienta de interpolación entre estilos artísticos para animación	VAE	Su espacio latente continuo facilita transiciones suaves y coherentes entre estilos.

Ejercicio 1.2: Trade-offs

Criterio	GANs	VAEs	Difusión	LLMs
Velocidad de generación	Alta	Alta	Baja	Alta
Calidad de salida	Alta	Media	Alta	Alta
Estabilidad de entrenamiento	Baja	Alta	Alta	Media
Control sobre la salida	Media	Alta	Alta	Alta
Facilidad de uso	Media	Alta	Media	Alta

Parte 2. Ciclo de Vida y Alineamiento de un LLM

Ejercicio 2.1: Ordenar el pipeline

Etapa	Orden
Recopilación de datos de entrenamiento	1
Pre-entrenamiento con predicción del siguiente token	2
Fine-tuning con datos del dominio	3
RLHF con feedback de evaluadores humanos	4
Evaluación y red-teaming de seguridad	5
Despliegue como API o producto	6

Ejercicio 2.2: Análisis de alineamiento

a) ¿Por qué el modelo base responde de manera literal? Porque durante el preentrenamiento su objetivo principal es predecir la continuación más probable del texto, no evaluar si la petición es ética o peligrosa. En otras palabras, aprende patrones lingüísticos e instrucciones, pero no criterios sólidos de seguridad por sí solo.

b) ¿Qué aprendió durante RLHF? Aprendió a priorizar respuestas alineadas con preferencias humanas, especialmente seguridad, utilidad y rechazo de usos dañinos. Por eso deja de ayudar con phishing y redirige al usuario hacia una alternativa legítima y segura.

c) ¿Puede el alineamiento ser excesivo? Sí. Habría over-refusal si el modelo se negara a explicar cómo funciona el phishing en un contexto educativo o de ciberseguridad cuyo objetivo es aprender a detectarlo y prevenirlo.

Parte 3. Tokenización y Parámetros

Ejercicio 3.1: Análisis de tokenización

Texto	Tokens	Observación
"Hello, world!"	5	Frase breve en inglés; palabras y puntuación comunes se comprimen bien.
"Hola, mundo!"	5	También es compacta, aunque en español frases más largas suelen fragmentarse más.
"Funcionamiento de transformers"	6	“Funcionamiento” puede dividirse en subpalabras; “transformers” suele ser compacto.
"def calculate_sum(a, b): return a + b"	13	El código genera más tokens por nombres, signos, espacios y operadores.
"日本語のテキスト"	11	El japonés y el carácter inicial no estándar pueden dividirse más, aunque los modelos nuevos lo manejan mejor.

Pregunta: El español y otros idiomas suelen requerir más tokens porque los tokenizadores trabajan con subpalabras frecuentes, y muchas combinaciones están más optimizadas para el inglés. Además, la morfología, los acentos y los sistemas de escritura no latinos hacen que algunas palabras se dividan en más fragmentos.

Ejercicio 3.2: Experimentación con parámetros

Configuración	Resultado esperado/obtenido
Temperature = 0.2	El bosque estaba cubierto por una niebla espesa que apenas dejaba pasar la luz de la luna. Entre los árboles reinaba un silencio inquietante, roto solo por el crujido de las ramas.
Temperature = 0.8	Una niebla plateada se enroscaba entre los troncos retorcidos del bosque, como si escondiera secretos antiguos. Cada sombra parecía moverse por sí sola, invitando y advirtiendo a quien se atreviera a entrar.
Temperature = 1.5	El bosque respiraba en susurros verdes, como si cada hoja guardara el eco de un sueño olvidado. La luna, atrapada entre ramas negras, parecía observar con ojos de criatura antigua.

Pregunta: Usaría temperature baja en tareas donde necesito precisión y consistencia, por ejemplo resumir un texto técnico o generar código. Usaría temperature alta en tareas creativas u abiertas, como escribir cuentos, generar ideas de campaña o producir descripciones literarias.

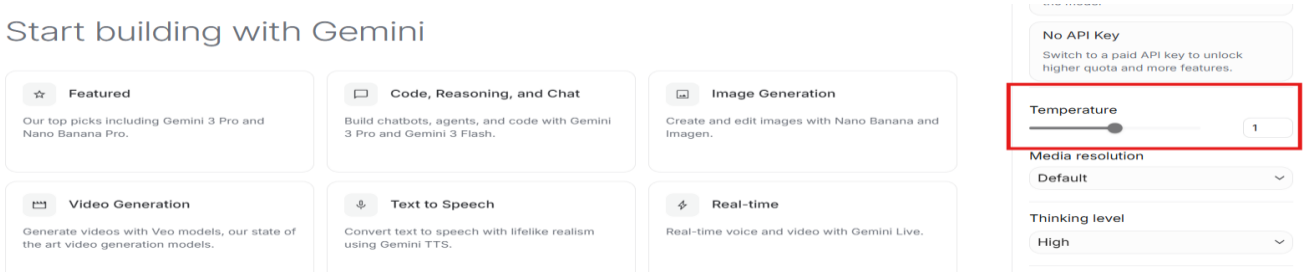

Parte 4. Reflexión Crítica

Ejercicio 4.1: Limitaciones

Limitación	Impacto en producción
Alucinaciones	Pueden producir respuestas convincentes pero falsas, lo que en producción obliga a validar la información, sobre todo en salud, finanzas o soporte técnico.
Conocimiento desactualizado	Puede ofrecer datos antiguos o incompletos; por eso suele combinarse con buscadores o sistemas RAG para usar información reciente.
Sesgos de entrenamiento	Puede reproducir prejuicios o desigualdades presentes en los datos, afectando la justicia, la experiencia del usuario y el cumplimiento ético.
Ventana de contexto limitada	Dificulta trabajar con documentos largos e historiales extensos, por lo que a menudo hay que resumir, fragmentar o priorizar información.

Ejercicio 4.2: Caso ético

a) Riesgos principales

- Posibles recomendaciones incorrectas o alucinadas que retrasen la atención médica real.
- Sesgos o bajo rendimiento en grupos poco representados o casos clínicos atípicos.
- Sobreconfianza del usuario en un sistema con 95% en benchmark pero sin garantía de seguridad en pacientes reales.

b) Medidas de mitigación

- Usarlo solo como apoyo o triaje, con supervisión humana obligatoria y derivación inmediata en señales de alarma.
- Validarlo clínicamente con datos reales, monitorizar errores y realizar auditorías periódicas de sesgo y seguridad.
- Proteger estrictamente los datos de salud, informar límites del sistema y prohibir su uso como diagnóstico autónomo.

c) ¿Debería desplegarse? No lo desplegaría como sistema autónomo de recomendación médica directa. Solo lo usaría como herramienta de apoyo, con límites claros, supervisión profesional y protocolos de escalado ante síntomas de riesgo. Aunque 95% parezca alto, en salud el 5% restante puede traducirse en daño serio, y un benchmark no sustituye la validación clínica en el mundo real. Por eso, la decisión final debería seguir en manos de personal sanitario.